ESGI - AL5 / T1

Apprentissage par renforcement

TP MDP : Snake

Processus de décision markoviens et Q-Learning

Rapport - Exercices 1 à 3

RUSESCU Daniel Alexandru
BAH Sulaiman
SEDJAI Fethi

Enseignant : Sylvain Gault
Date : 5 novembre 2026

Répartition du travail

Toutes les parties ont été réalisées ensemble par les trois membres du groupe : conception, code, tests, graphiques, analyse, rédaction et relecture. La mention « Travail collectif » associée à chaque question renvoie à cette répartition commune.

Code source : dépôt GitHub du groupe - github.com/Sulaimanzy/mdp-snake-alex-sulaiman-fethi

Sommaire

Reproduction des résultats

Exercice 1 - Jeu de base

- Question 1.1 - Classe ShortSnake et grille
- Question 1.2 - Position et direction initiales
- Question 1.3 - Position aléatoire du fruit
- Question 1.4 - Score
- Question 1.5 - Méthode move
- Question 1.6 - Franchissement d'un bord
- Question 1.7 - Fruit mangé
- Question 1.8 - Affichage __str__

Exercice 2 - Modélisation du MDP

- Question 2.1 - Informations constituant un état
- Question 2.2 - Nombre d'états pour une grille 10 × 10
- Question 2.3 - Grille N × M
- Question 2.4 - Actions du MDP
- Question 2.5 - Les actions dépendent-elles de l'état ?
- Question 2.6 - Récompenses du MDP
- Question 2.7 - Représentation graphique du MDP

Exercice 3 - Implémentation du Q-Learning

- Question 3.1 - Méthode save_state
- Question 3.2 - Méthode restore_state
- Question 3.3 - Formule de mise à jour du Q-Learning
- Question 3.4 - Reprise de GreedyPlayer du TP précédent
- Question 3.5 - Constructeur avec une instance de ShortSnake
- Question 3.6 - Tableau Q indexé par (état, action)
- Question 3.7 - _greedy_action tient compte de l'état
- Question 3.8 - Mise à jour du Q-Learning dans reward (γ = 0,5)
- Question 3.9 - Programme principal
- Question 3.10 - Évolution de la récompense sur 1000 étapes
- Question 3.11 - Nombre de relances pour lisser le bruit
- Question 3.12 - Comparaison de γ = 0 ; 0,1 ; 0,5 ; 0,9 et 1
- Question 3.13 - Recherche de la meilleure valeur de γ
- Question 3.14 - Sur 10 000 étapes
- Pour aller plus loin - entraînements de 1 000 000 d'étapes

Reproduction des résultats

- Python 3.14 (toute version ≥ 3.8 convient). Le jeu et le modèle MDP n'ont besoin d'aucune dépendance ; `matplotlib` sert aux figures, `markdown`, `pygments` et `pymupdf` à générer ce rapport.
- Depuis la racine du dépôt :

```
py -m pip install -r requirements.txt   # dépendances (figures et rapport)
py -m unittest discover tests           # tests du jeu, du modèle MDP, du joueur et des
statistiques
py ex1_demo.py                          # exercice 1 : partie scriptée
py ex1_demo.py --play                   # exercice 1 : jouer au clavier (z q s d + Entrée)
py ex2_mdp.py                           # exercice 2 : réponses calculées + figure du MDP
py ex3_qlearning.py play                # exercice 3 : l'IA apprend puis on la regarde jouer
py ex3_qlearning.py all                 # exercice 3 : toutes les expériences (≈ 4 min sur 32
cœurs)
py rapport/build_pdf.py                 # régénère ce rapport en PDF
```

Les expériences de l'exercice 3 peuvent aussi être lancées une à une (`q10`, `q11`, `q12`, `q13`, `q14`, `long`). Toutes les graines aléatoires sont fixées : la partie `i` utilise la graine `i` pour le jeu et `1 000 000 + i` pour le joueur, quel que soit γ. Les résultats sont donc reproductibles à l'identique.

Fichiers :

Fichier	Contenu
`snake.py`	classe `ShortSnake` (mécanique du jeu)
`ex1_demo.py`	démonstration de l'exercice 1
`mdp.py`	modèle MDP du jeu : états, actions, dynamique p(s', r | s, a)
`ex2_mdp.py`	réponses de l'exercice 2 et figure `rapport/figures/ex2_mdp.png`
`greedy_player.py`	joueur Q-Learning ε-greedy (repris du TP Bandit manchot)
`ex3_qlearning.py`	programme principal et expériences de l'exercice 3
`resultats/*.csv`	résultats chiffrés des expériences de l'exercice 3
`tests/test_snake.py`	tests unitaires de `ShortSnake`
`tests/test_mdp.py`	tests du modèle MDP (comptages, probabilités, cohérence avec le jeu)
`tests/test_qlearning.py`	tests de `save_state` / `restore_state`, du joueur et du programme principal
`rapport/rapport.md`	source de ce rapport
`rapport/build_pdf.py`	conversion du rapport en PDF (Markdown → HTML → PDF via Edge ou Chrome)

Exercice 1 - Jeu de base

Convention : les coordonnées sont des tuples `(ligne, colonne)`, `(0, 0)` étant le coin en haut à gauche. Les directions sont les chaînes `UP`, `DOWN`, `LEFT`, `RIGHT`.

```
EMPTY, SNAKE, FRUIT = 0, 1, 2

UP, DOWN, LEFT, RIGHT = "UP", "DOWN", "LEFT", "RIGHT"
DIRECTIONS = {UP: (-1, 0), DOWN: (1, 0), LEFT: (0, -1), RIGHT: (0, 1)}
OPPOSITE = {UP: DOWN, DOWN: UP, LEFT: RIGHT, RIGHT: LEFT}

WALL_PENALTY = -10
FRUIT_REWARD = 10
```

Question 1.1 - Classe `ShortSnake` et grille

Travail collectif

```
class ShortSnake:
    def __init__(self, size=10, seed=None):
        if isinstance(size, int):
            size = (size, size)
        self.n_rows, self.n_cols = size
        if self.n_rows < 1 or self.n_cols < 1 or self.n_rows * self.n_cols < 2:
            raise ValueError("la grille doit contenir au moins 2 cases")
        self.grid = [[EMPTY] * self.n_cols for _ in range(self.n_rows)]
        self.rng = random.Random(seed)
```

La taille est un entier (grille carrée) ou un couple `(lignes, colonnes)`. La grille est une liste de listes dont chaque case vaut `EMPTY`, `SNAKE` ou `FRUIT`. Il faut au moins 2 cases pour pouvoir placer le serpent et le fruit. Le générateur `rng` peut recevoir une graine pour rendre une partie reproductible.

Question 1.2 - Position et direction initiales

Travail collectif

```
        self.snake_pos = (self.n_rows // 2, self.n_cols // 2)
        self.snake_dir = RIGHT
        self._set_cell(self.snake_pos, SNAKE)

    def _set_cell(self, pos, value):
        row, col = pos
        self.grid[row][col] = value
```

Le serpent démarre au milieu de la grille (`(5, 5)` pour une grille 10 × 10) et part vers la droite.

Question 1.3 - Position aléatoire du fruit

Travail collectif

```
        self.fruit_pos = self._place_fruit()

    def _place_fruit(self):
        free_cells = [
            (row, col)
            for row in range(self.n_rows)
            for col in range(self.n_cols)
            if self.grid[row][col] == EMPTY
        ]
        pos = self.rng.choice(free_cells)
        self._set_cell(pos, FRUIT)
        return pos
```

Le fruit est tiré uniformément parmi les cases libres, il n'apparaît donc jamais sous le serpent.

Question 1.4 - Score

Travail collectif

```
        self.score = 0
```

Question 1.5 - Méthode `move`

Travail collectif

```
    def move(self, direction=None):
        if direction is not None:
            if direction not in DIRECTIONS:
                raise ValueError(f"direction inconnue : {direction!r}")
            if direction != OPPOSITE[self.snake_dir]:
                self.snake_dir = direction

        d_row, d_col = DIRECTIONS[self.snake_dir]
        row, col = self.snake_pos[0] + d_row, self.snake_pos[1] + d_col
        reward = 0
        ...
        self._set_cell(self.snake_pos, EMPTY)
        self.snake_pos = (row, col)
        self._set_cell(self.snake_pos, SNAKE)
        ...
        self.score += reward
        return reward
```

`None` garde la direction courante. Une demande de demi-tour est ignorée : le serpent continue dans sa direction actuelle. La méthode renvoie la récompense de l'étape, qui servira au Q-Learning (exercice 3).

Question 1.6 - Franchissement d'un bord

Travail collectif

```
        if not (0 <= row < self.n_rows and 0 <= col < self.n_cols):
            row %= self.n_rows
            col %= self.n_cols
            reward += WALL_PENALTY
```

Le modulo fait réapparaître le serpent du côté opposé (ligne `-1` → ligne `n_rows - 1`, colonne `n_cols` → colonne `0`), avec une pénalité de 10 points.

Question 1.7 - Fruit mangé

Travail collectif

```
        if self.snake_pos == self.fruit_pos:
            reward += FRUIT_REWARD
            self.fruit_pos = self._place_fruit()
```

Le test a lieu après le déplacement de la tête : la case du fruit est déjà marquée `SNAKE`, donc le nouveau fruit est tiré parmi les autres cases. Si le serpent franchit un bord et tombe sur le fruit, les deux récompenses s'additionnent (−10 + 10 = 0).

Question 1.8 - Affichage `__str__`

Travail collectif

```
HEAD_SYMBOL = {UP: "^", DOWN: "v", LEFT: "<", RIGHT: ">"}
CELL_SYMBOL = {EMPTY: ".", FRUIT: "*"}

    def __str__(self):
        border = "+" + "-" * self.n_cols + "+"
        lines = [border]
        for row in self.grid:
            cells = (
                HEAD_SYMBOL[self.snake_dir] if cell == SNAKE else CELL_SYMBOL[cell]
                for cell in row
            )
            lines.append("|" + "".join(cells) + "|")
        lines.append(border)
        lines.append(f"Score : {self.score}")
        return "\n".join(lines)
```

La tête est dessinée par une flèche qui indique sa direction. Extrait de `py ex1_demo.py` (grille 5 × 8, graine 42) :

```
Étape 5 : move(UP) -> récompense +10 (on mange le fruit : +10)
+--------+
|.*.....^|
|........|
|........|
|........|
|........|
+--------+
Score : 10

Étape 6 : move(UP) -> récompense -10 (bord du haut franchi : on réapparaît en bas, -10)
+--------+
|.*......|
|........|
|........|
|........|
|.......^|
+--------+
Score : 0
```

Les 17 tests de `tests/test_snake.py` vérifient chacun de ces comportements (position initiale, demi-tour ignoré, passage des quatre bords, fruit mangé, cohérence de la grille, affichage).

Exercice 2 - Modélisation du MDP

Le modèle est codé dans `mdp.py` ; `ex2_mdp.py` en déduit les réponses. Sortie de `py ex2_mdp.py` :

```
Q2.1  état = (tête, direction, fruit) = ((5, 5), 'RIGHT', (4, 9))
Q2.2  grille 10 x 10 : 39600 états (énumérés : 39600, atteignables : 39600)
Q2.3  |S| = 4·N·M·(N·M − 1) : {'3x3': 288, '4x5': 1520, '10x10': 39600, '20x20': 638400}
Q2.4  arguments de move : [None, 'UP', 'DOWN', 'LEFT', 'RIGHT']
      actions regroupées par effet dans ((5, 5), 'RIGHT', (4, 9)) : [[None, 'LEFT', 'RIGHT'],
['UP'], ['DOWN']]
Q2.5  A(s) si direction = UP    : ['UP', 'LEFT', 'RIGHT']
Q2.5  A(s) si direction = DOWN  : ['DOWN', 'LEFT', 'RIGHT']
Q2.5  A(s) si direction = LEFT  : ['UP', 'DOWN', 'LEFT']
Q2.5  A(s) si direction = RIGHT : ['UP', 'DOWN', 'RIGHT']
Q2.6  récompenses possibles : [-10, 0, 10]
      exemple bord  : [(1.0, ((5, 0), 'RIGHT', (0, 0)), -10)]
      exemple fruit : 99 états suivants, p = 1/99, r = 10
```

Question 2.1 - Informations constituant un état

Travail collectif

```python
def state_of(game):
    """État du MDP pour une partie en cours : (tête, direction, fruit)."""
    return (game.snake_pos, game.snake_dir, game.fruit_pos)
```

Un état contient tout ce qui détermine la suite du jeu (propriété de Markov) :

- la **position de la tête** `(ligne, colonne)` ;
- la **direction courante** : elle fixe l'effet de `None` (continuer tout droit) et le demi-tour interdit. Sans elle, la transition dépendrait des coups précédents ;
- la **position du fruit**, qui fixe la récompense des prochains déplacements.

Le score n'en fait pas partie : c'est la somme des récompenses déjà reçues, il n'influence pas la suite du jeu et rendrait l'ensemble des états infini. La grille non plus : elle se déduit de la tête et du fruit.

Question 2.2 - Nombre d'états pour une grille 10 × 10

Travail collectif

```python
def n_states(n_rows, n_cols):
    """|S| = N·M positions de tête × 4 directions × (N·M − 1) positions du fruit."""
    n_cells = n_rows * n_cols
    return n_cells * len(DIRECTIONS) * (n_cells - 1)


def all_states(size):
    """Énumère tous les états : le fruit n'est jamais sous la tête."""
    grid_cells = cells(size)
    return [
        (head, direction, fruit)
        for head in grid_cells
        for direction in DIRECTIONS
        for fruit in grid_cells
        if fruit != head
    ]
```

100 × 4 × 99 = 39 600 états. Le fruit n'est jamais sur la tête : dès que le serpent l'atteint, il est mangé et replacé sur une autre case. Le dénombrement est confirmé par l'énumération, et un parcours en largeur du graphe du MDP (`reachable_states`) montre que les 39 600 états sont tous atteignables depuis l'état initial.

Question 2.3 - Grille N × M

Travail collectif

Même fonction `n_states(n_rows, n_cols)` :

|S| = 4 · N · M · (N · M − 1)

Grille	3 × 3	4 × 5	10 × 10	20 × 20
États	288	1 520	39 600	638 400

Le nombre d'états croît comme le carré du nombre de cases. Le test `test_count_formula` vérifie la formule par énumération sur plusieurs tailles.

Question 2.4 - Actions du MDP

Travail collectif

```python
MOVE_ARGUMENTS = [None, UP, DOWN, LEFT, RIGHT]   # arguments acceptés par move

_LEGAL_ACTIONS = {
    direction: [d for d in DIRECTIONS if d != OPPOSITE[direction]]
    for direction in DIRECTIONS
}


def actions(state):
    """A(s) : les quatre directions sauf le demi-tour (None équivaut à la direction courante)."""
    return _LEGAL_ACTIONS[state[1]]
```

Les listes sont calculées une seule fois par direction, car `actions` est appelée plusieurs fois à chaque étape du Q-Learning (exercice 3).

`move` accepte cinq arguments, mais ils n'ont que **trois effets distincts** : continuer tout droit, tourner à gauche, tourner à droite. Dans l'état `((5, 5), RIGHT, …)`, `None`, `LEFT` (demi-tour ignoré) et `RIGHT` mènent au même état. On retient donc comme actions du MDP les trois directions qui ne sont pas un demi-tour.

Question 2.5 - Les actions dépendent-elles de l'état ?

Travail collectif

```
for direction in (UP, DOWN, LEFT, RIGHT):
    print(f"A(s) si direction = {direction:5} :", actions(((5, 5), direction, (0, 0))))
```

Oui : $\mathcal{A}(s)$ = {UP, DOWN, LEFT, RIGHT} \ {opposé de la direction de s}. Seule la direction de l'état intervient, pas la position de la tête ni celle du fruit. On aurait pu modéliser des actions relatives (tout droit, gauche, droite), identiques dans tous les états ; leur effet absolu dépendrait alors de la direction. Nous gardons les directions absolues, qui correspondent directement aux arguments de `move`.

Question 2.6 - Récompenses du MDP

Travail collectif

```
def transitions(state, action, size):
    """p(s', r | s, a) sous forme de liste de (probabilité, état suivant, récompense)."""
    n_rows, n_cols = _size(size)
    (row, col), direction, fruit = state

    if action is not None and action != OPPOSITE[direction]:
        direction = action
    d_row, d_col = DIRECTIONS[direction]
    row, col = row + d_row, col + d_col

    reward = 0
    if not (0 <= row < n_rows and 0 <= col < n_cols):
        row, col = row % n_rows, col % n_cols
        reward += WALL_PENALTY
    head = (row, col)

    if head != fruit:  # déplacement déterministe
        return [(1.0, (head, direction, fruit), reward)]

    # Fruit mangé : le nouveau fruit est uniforme sur les N·M − 1 autres cases
    reward += FRUIT_REWARD
    free_cells = [cell for cell in cells(size) if cell != head]
    prob = 1 / len(free_cells)
    return [(prob, (head, direction, new_fruit), reward) for new_fruit in free_cells]
```

$\mathscr{R}$ = {−10, 0, +10} :

Situation	Récompense
fruit mangé	+10
bord franchi	−10
bord franchi et fruit mangé au même pas	−10 + 10 = 0
autre déplacement	0

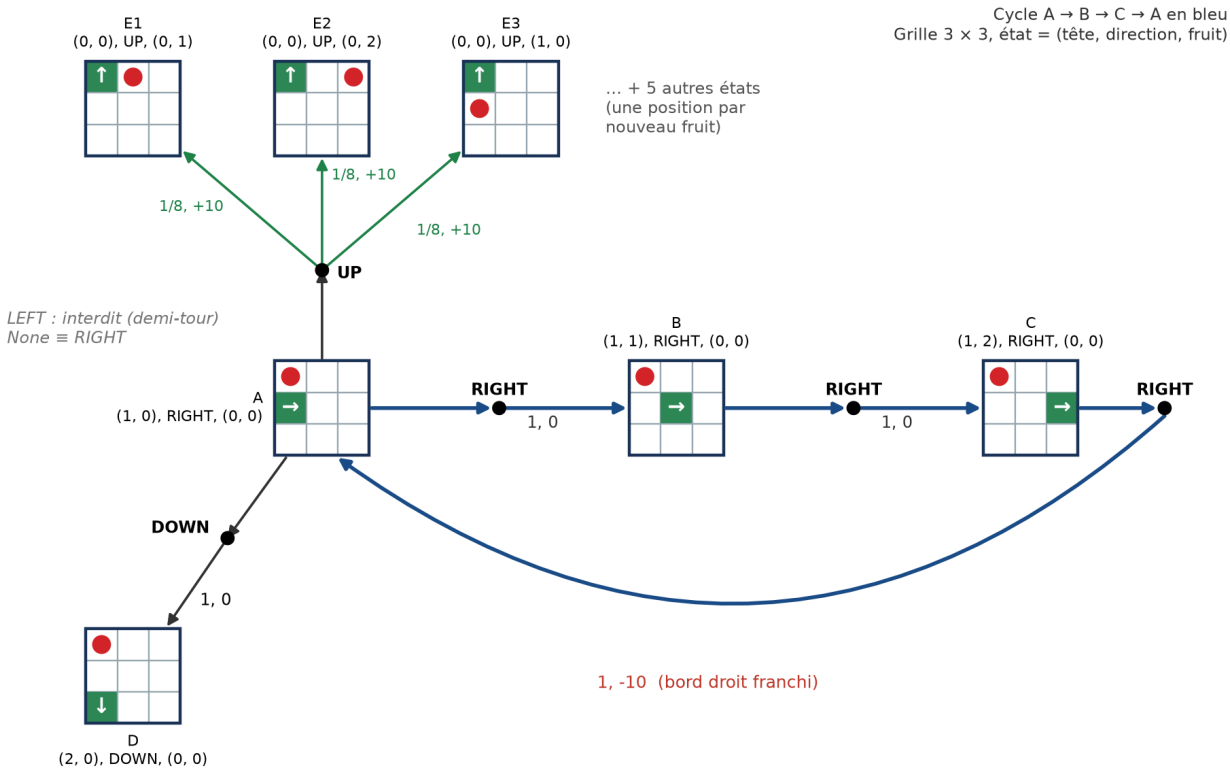
La fonction donne la dynamique complète p(s', r | s, a) du cours. Le déplacement est déterministe ; seul le placement du nouveau fruit est aléatoire, avec une probabilité 1 / (N·M − 1) pour chaque case libre. Il n'y a pas d'état final : c'est une tâche continue. Le test `test_model_matches_game` joue 2 000 coups aléatoires avec `ShortSnake` et vérifie que chaque résultat du jeu est bien prévu par `transitions`.

Question 2.7 - Représentation graphique du MDP

Travail collectif

```
def draw_mdp_figure(path):
    size = (3, 3)

    # États du cycle, obtenus avec le modèle p(s', r | s, a)
    A = ((1, 0), RIGHT, (0, 0))
    [(p_ab, B, r_ab)] = transitions(A, RIGHT, size)
    [(p_bc, C, r_bc)] = transitions(B, RIGHT, size)
    [(p_ca, back, r_ca)] = transitions(C, RIGHT, size)
    assert back == A, "RIGHT trois fois depuis A doit revenir en A"
    [(p_ad, D, r_ad)] = transitions(A, DOWN, size)
    eaten = transitions(A, UP, size)  # fruit mangé : 8 états suivants
    ...  # dessin avec matplotlib (mini-grilles, points d'action, flèches « p, r »)
```



La figure reprend la notation du cours (robot aspirateur) sur une grille 3 × 3 : chaque état est dessiné par sa mini-grille (tête verte fléchée, fruit rouge), chaque point noir est une action, chaque flèche porte « probabilité, récompense ».

- **Cycle A → B → C → A** (en bleu) : en répétant `RIGHT` sur la ligne du milieu, le serpent traverse le bord droit et revient en A. Les récompenses du cycle sont 0, 0 et −10.
- **Action UP depuis A** : la tête arrive sur le fruit (+10) ; le nouveau fruit est tiré parmi les 8 autres cases, d'où 8 états suivants de probabilité 1/8 (3 sont dessinés).
- **Action DOWN depuis A (vers D)** : déplacement déterministe sans récompense.
- **LEFT** est un demi-tour depuis A : il n'est pas dans $\mathcal{A}$(A), et `None` équivaut à `RIGHT`. Pour B et C, seule l'action du cycle est représentée.

Exercice 3 - Implémentation du Q-Learning

Question 3.1 - Méthode `save_state`

Travail collectif

```
    def save_state(self):
        """Renvoie l'état actuel du jeu : (tête, direction, fruit).

        C'est l'état du MDP (exercice 2) : le score n'en fait pas partie, c'est la
        somme des récompenses déjà reçues.
        """
        return (self.snake_pos, self.snake_dir, self.fruit_pos)
```

Le tuple contient exactement l'état du MDP de la question 2.1. Il est hachable, ce qui permet de l'utiliser directement comme clé du tableau Q. Y ajouter le score rendrait chaque état unique : l'agent ne reverrait jamais deux fois le même état et ne pourrait rien apprendre.

Question 3.2 - Méthode `restore_state`

Travail collectif

```
    def _as_cell(self, pos):
        """Convertit `pos` en tuple (ligne, colonne) d'entiers dans la grille."""
        try:
            row, col = (operator.index(x) for x in pos)
        except (TypeError, ValueError):
            raise ValueError(f"case invalide : {pos!r}") from None
        if not (0 <= row < self.n_rows and 0 <= col < self.n_cols):
            raise ValueError(f"case hors de la grille : {(row, col)}")
        return (row, col)

    def restore_state(self, state):
        """Remet le jeu dans un état renvoyé par save_state (le score est inchangé).

        Toutes les vérifications ont lieu avant la moindre modification du jeu.
        """
        try:
            head, direction, fruit = state
        except (TypeError, ValueError):
            raise ValueError(f"état invalide : {state!r}") from None
        head, fruit = self._as_cell(head), self._as_cell(fruit)
        if not isinstance(direction, str) or direction not in DIRECTIONS:
            raise ValueError(f"direction inconnue : {direction!r}")
        if head == fruit:
            raise ValueError("le fruit ne peut pas être sous le serpent")

        self.grid = [[EMPTY] * self.n_cols for _ in range(self.n_rows)]
        self.snake_pos, self.snake_dir, self.fruit_pos = head, direction, fruit
        self._set_cell(head, SNAKE)
        self._set_cell(fruit, FRUIT)
```

La grille est reconstruite à partir de l'état, ce qui la garde cohérente avec `snake_pos` et `fruit_pos`. Les positions sont converties en tuples d'entiers, pour que l'état restauré reste hachable, et un état invalide est refusé avant toute modification du jeu.

Le score et le générateur aléatoire ne sont pas restaurés : ils ne font pas partie de l'état du MDP. Depuis un même état restauré, le même coup mène donc au même état lorsqu'aucun fruit n'est mangé. Quand un fruit est mangé, le nouveau fruit est tiré au hasard, comme le prévoit p(s', r | s, a).

Les tests vérifient trois choses : l'aller-retour `save_state` → `restore_state`, le rejet des états invalides sans effet sur le jeu, et qu'un coup rejoué avec la même graine donne le même résultat. `restore_state` remplace aussi l'ancien utilitaire de test de l'exercice 2.

Question 3.3 - Formule de mise à jour du Q-Learning

Travail collectif

```python
    def reward(self, action, value):   # extrait, méthode complète à la question 3.8
        ...
        cible = value + self.gamma * meilleure_suite
        ...
        self.action_values[cle] = (
            (1 - self.alpha) * self.action_values.get(cle, 0.0) + self.alpha * cible
        )
```

$$Q(s_t, a_t) \leftarrow (1 - \alpha) \cdot Q(s_t, a_t) + \alpha \cdot (R_t + \gamma \cdot \max_a Q(s_{t+1}, a))$$

- R_t est la récompense reçue après l'action a_t (notation du cours), s_{t+1} l'état d'arrivée ;
- $\alpha \in]0, 1]$ est le taux d'apprentissage, $\gamma \in [0, 1]$ le facteur d'actualisation ;
- le maximum porte sur les actions possibles dans s_{t+1}, sans demi-tour.

La valeur estimée est le retour actualisé $G_t = R_{t+1} + \gamma G_{t+1}$ du cours : on remplace G_{t+1} par la meilleure valeur connue depuis l'état d'arrivée.

Question 3.4 - Reprise de `GreedyPlayer` du TP précédent

Travail collectif

```python
class GreedyPlayer:
    """Apprend Q(état, action) par Q-Learning en jouant à ShortSnake."""

    ...   # constructeur (question 3.5)

    def get_action(self):
        """Explore avec la probabilité eps, sinon exploite les estimations."""
        self.state = self.game.save_state()
        explore = self.rng.random() < self.eps
        if explore:
            return self._random_action(self.state)
        return self._greedy_action(self.state)

    def _random_action(self, state):
        """Choisit uniformément parmi les actions possibles dans `state`."""
        return self.rng.choice(actions(state))
```

La classe garde la structure du TP Bandit manchot (`greedy_player.py`) : mêmes méthodes, mêmes noms (`eps`, `action_values`, `eval_count`), même stratégie ε-greedy et même départage aléatoire des égalités.

Méthode	TP Bandit manchot	TP Snake
constructeur	`GreedyPlayer(n, eps)`	`GreedyPlayer(game, eps, alpha, gamma, seed)`
`action_values`	liste indexée par l'action	dictionnaire indexé par (état, action)
`get_action`	ε-greedy	ε-greedy, mémorise l'état courant
`_greedy_action`	`argmax` sur les actions	`argmax` sur les actions possibles dans l'état
`_random_action`	`randrange(n)`	tirage parmi les 3 actions possibles
`reward(action, value)`	moyenne incrémentale	mise à jour du Q-Learning

Le générateur aléatoire est propre au joueur (`random.Random(seed)`), pour que chaque partie soit reproductible.

Question 3.5 - Constructeur avec une instance de `ShortSnake`

Travail collectif

```
    def __init__(self, game, eps, alpha=0.5, gamma=0.5, seed=None):
        if not 0 <= eps <= 1:
            raise ValueError("Epsilon doit être compris entre 0 et 1.")
        if not 0 < alpha <= 1:
            raise ValueError("Alpha doit être compris dans ]0, 1].")
        if not 0 <= gamma <= 1:
            raise ValueError("Gamma doit être compris entre 0 et 1.")

        self.game = game          # instance de ShortSnake
        self.eps = eps
        self.alpha = alpha        # taux d'apprentissage
        self.gamma = gamma        # facteur d'actualisation
        self.action_values = {}   # Q[(état, action)], 0 si jamais mis à jour
        self.eval_count = {}      # nombre de mises à jour de chaque paire (état, action)
        self.rng = random.Random(seed)
        self.state = None         # état dans lequel la dernière action a été choisie
```

Le joueur lit l'état du jeu avec `game.save_state()` . Le nombre d'actions `n` du TP précédent disparaît : les actions possibles dépendent maintenant de l'état (question 2.5).

Question 3.6 - Tableau Q indexé par (état, action)

Travail collectif

```
        self.action_values = {}   # Q[(état, action)], 0 si jamais mis à jour   (constructeur)
        ...

    def _value(self, state, action):
        return self.action_values.get((state, action), 0.0)
```

Un dictionnaire évite de réserver d'avance les 39 600 × 3 = 118 800 paires d'une grille 10 × 10 : seules les paires effectivement rencontrées sont stockées. Une paire absente vaut 0, comme l'initialisation

`[0.0] * n` du TP précédent.

Question 3.7 - `_greedy_action` tient compte de l'état

Travail collectif

```
    def _greedy_action(self, state):
        """Choisit une action de valeur Q(state, a) maximale, au hasard en cas d'égalité."""
        valeurs = [(action, self._value(state, action)) for action in actions(state)]
        meilleure_valeur = max(valeur for _, valeur in valeurs)
        meilleures_actions = [
            action for action, valeur in valeurs if valeur == meilleure_valeur
        ]
        return self.rng.choice(meilleures_actions)
```

Le maximum est pris sur les seules actions possibles dans l'état courant. Le test `test_greedy_uses_current_state` vérifie qu'une grande valeur Q associée à un autre état n'influence pas le choix.

Question 3.8 - Mise à jour du Q-Learning dans `reward` (γ = 0,5)

Travail collectif

```
    def reward(self, action, value):
        """Met à jour Q(s, a) après game.move(action), qui a rapporté `value`.

        Q(s, a) <- (1 - alpha) Q(s, a) + alpha (r + gamma max_a' Q(s', a'))
        """
        if self.state is None:
            raise RuntimeError("get_action doit être appelée avant reward.")
        if action not in actions(self.state):
            raise ValueError(f"action impossible dans l'état {self.state} : {action!r}")

        etat_suivant = self.game.save_state()
        meilleure_suite = max(self._value(etat_suivant, a) for a in actions(etat_suivant))
        cible = value + self.gamma * meilleure_suite

        cle = (self.state, action)
        self.action_values[cle] = (
            (1 - self.alpha) * self.action_values.get(cle, 0.0) + self.alpha * cible
        )
        self.eval_count[cle] = self.eval_count.get(cle, 0) + 1
        self.state = None   # une seule mise à jour par action choisie
```

La signature `reward(action, value)` est celle du TP précédent. L'état de départ s est celui mémorisé par `get_action`, et l'état d'arrivée s′ est lu dans le jeu après `move`. γ vaut 0,5 par défaut. Un second appel à `reward` sans nouvel appel à `get_action` est refusé. Les tests `test_q_learning_update` et `test_update_with_wall_penalty_and_gamma_zero` comparent le résultat à un calcul fait à la main.

Question 3.9 - Programme principal

Travail collectif

```
SIZE = 10           # grille 10 x 10
EPS = 0.1           # probabilité d'exploration
ALPHA = 0.5         # taux d'apprentissage
...


def play(player, game, n_steps):
    """Fait jouer l'IA pendant n_steps étapes ; renvoie la récompense de chaque étape."""
    rewards = np.empty(n_steps, dtype=np.int8)
    for t in range(n_steps):
        action = player.get_action()
        value = game.move(action)
        player.reward(action, value)
        rewards[t] = value
    return rewards


def run(gamma, n_steps, seed, eps=EPS, alpha=ALPHA):
    """Une partie complète avec une IA neuve (graines fixées pour la reproductibilité)."""
    game = ShortSnake(SIZE, seed=seed)
    player = GreedyPlayer(game, eps, alpha=alpha, gamma=gamma, seed=1_000_000 + seed)
    return play(player, game, n_steps)
```

La boucle reprend celle du TP précédent : choisir une action, la jouer, transmettre la récompense. `run_many` relance `run` sur plusieurs graines en parallèle (`ProcessPoolExecutor`). La commande `py ex3_qlearning.py play` entraîne l'IA pendant 500 000 étapes, puis affiche quelques coups joués sans exploration :

```
Entraînement : 500000 étapes en 3.7 s, score 103660, récompense moyenne sur les 1000 dernières
étapes +0.860, 105907 paires (état, action) apprises

Étape 4 : UP -> +0            Étape 5 : RIGHT -> +0         Étape 6 : RIGHT -> +10
+----------+                  +----------+                  +----------+
|..........|                  |..........|                  |..........|
|..........|                  |..........|                  |..........|
|..........|                  |..........|                  |..........|
|.......^.*|                  |........>*|                  |.........>|
|..........|                  |..........|                  |..........|
|..........|                  |..........|                  |..........|
|..........|                  |..........|                  |.*........|
|..........|                  |..........|                  |..........|
|..........|                  |..........|                  |..........|
|..........|                  |..........|                  |..........|
+----------+                  +----------+                  +----------+
Score : 103670                Score : 103670                Score : 103680
```

(Les trois grilles, affichées l'une sous l'autre par le programme, sont mises côte à côte ici.)

Les hyperparamètres restent fixes dans tout l'exercice : $\varepsilon = 0{,}1$ et $\alpha = 0{,}5$, sur une grille 10×10.

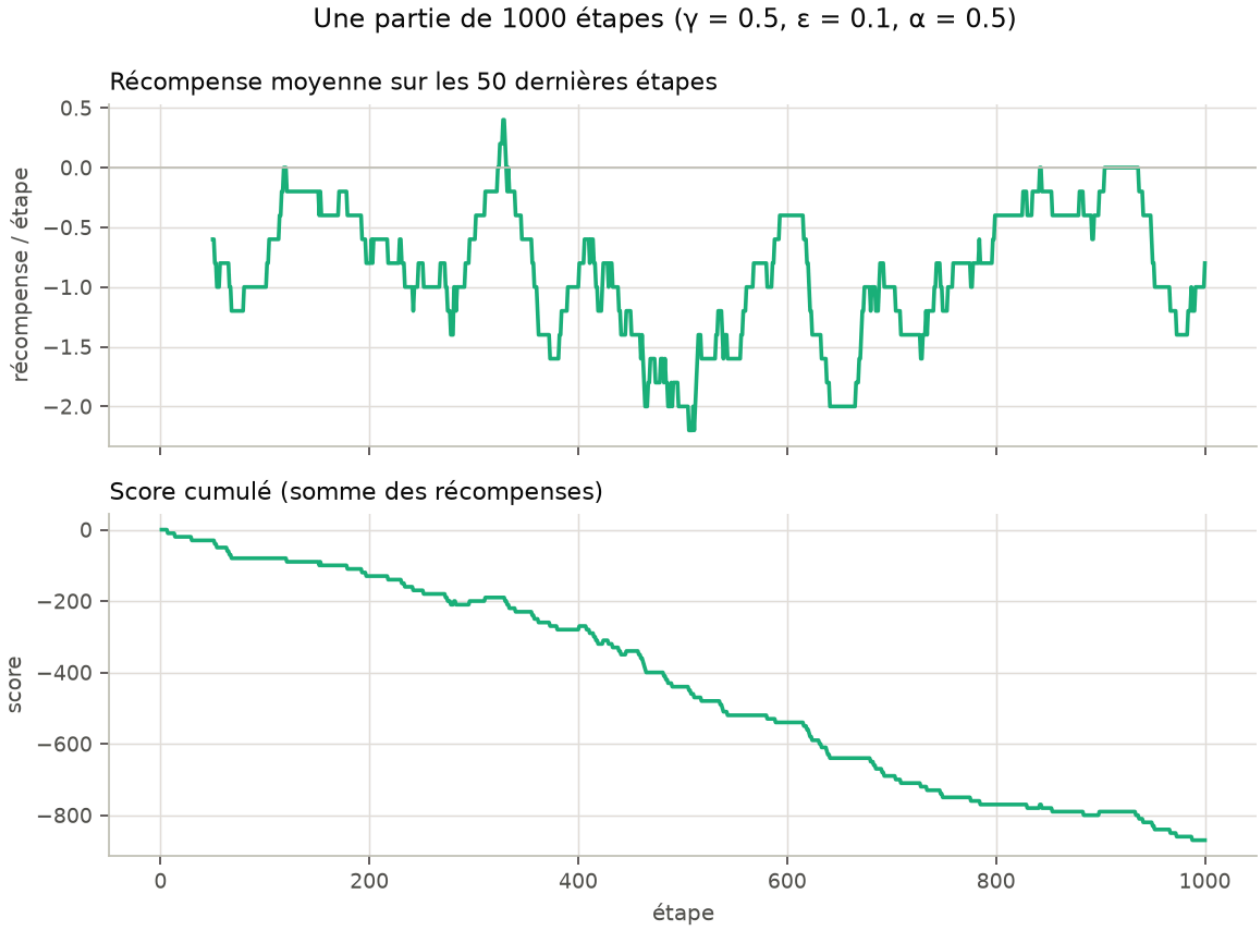
Question 3.10 - Évolution de la récompense sur 1000 étapes

Travail collectif

```
def q10(pool):
    rewards = run(0.5, 1000, seed=0)
    steps = np.arange(1, len(rewards) + 1)
    ...
    window = 50
    ax1.plot(steps[window - 1:], moving_average(rewards, window), ...)   # récompense glissante
    ...
    ax2.plot(steps, np.cumsum(rewards), ...)                             # score cumulé
    ...
```

`py ex3_qlearning.py q10` :

```
Q3.10 : une partie de 1000 étapes, γ = 0.5
  score final -870 ; 9 étapes à +10, 96 étapes à -10
```



La récompense d'une étape vaut −10, 0 ou +10 : on trace sa moyenne glissante sur 50 étapes et le score cumulé. En 1000 étapes, l'IA mange 9 fruits et franchit 96 bords : le score baisse presque linéairement, d'environ 0,9 point par étape. Sur une seule partie, la courbe est dominée par le bruit (entre −2,2 et +0,4) et aucune tendance n'apparaît.

Question 3.11 - Nombre de relances pour lisser le bruit

Travail collectif

```
def q11(pool):
    batch_a = run_many(pool, 0.5, 1000, 1000)                          # graines 0 à 999
    batch_b = run_many(pool, 0.5, 1000, 1000, first_seed=100_000)      # graines indépendantes
    ...
    for ax, k in zip(axes.flat, (1, 10, 100, 1000)):
        curve_a = moving_average(batch_a[:k].mean(axis=0), window)
        curve_b = moving_average(batch_b[:k].mean(axis=0), window)
        rms = float(np.sqrt(np.mean((curve_a - curve_b) ** 2)))
        mean_total, ci = total_stats(batch_a[:k])
        ...   # tableau et graphique

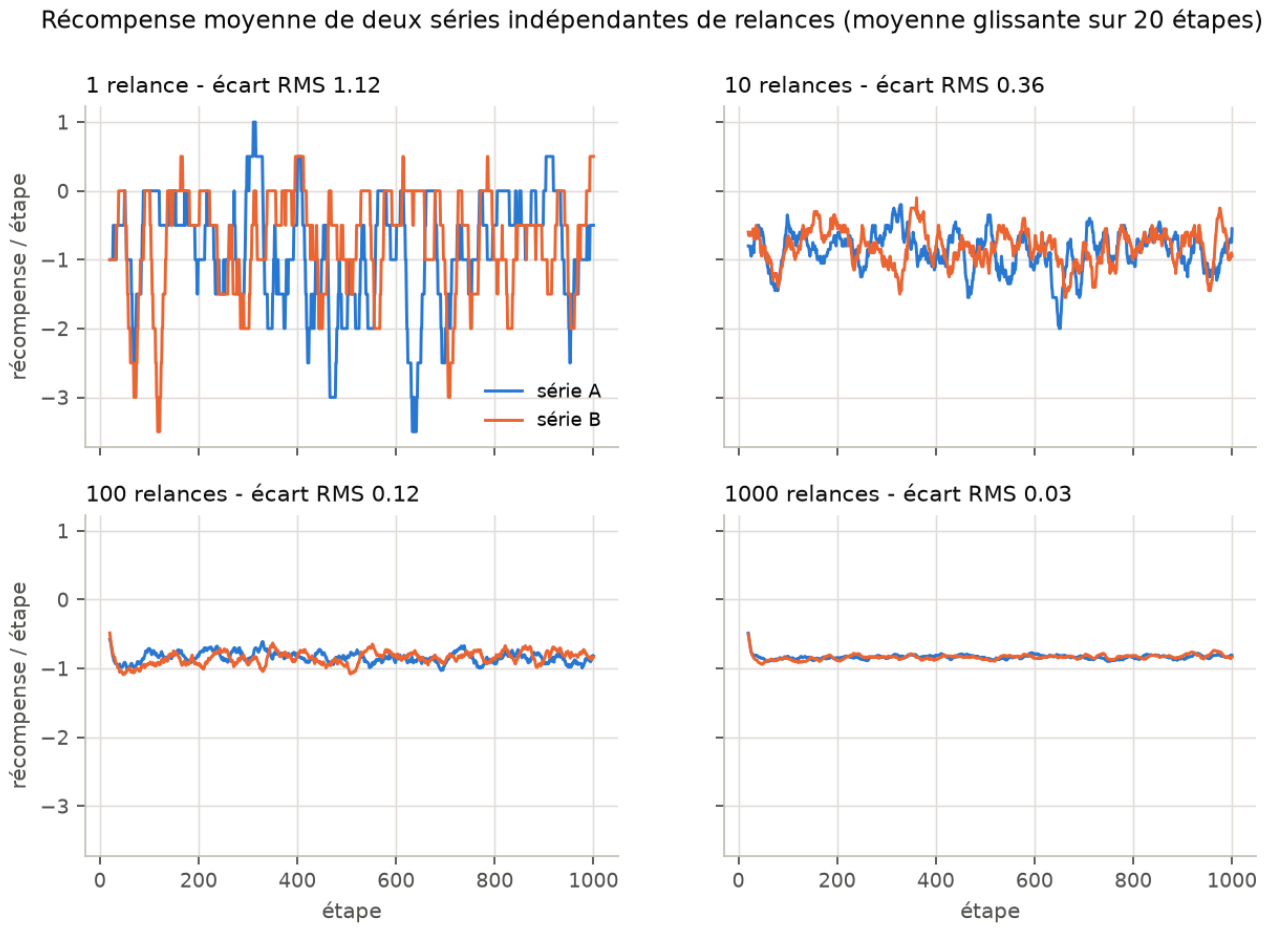

def mean_ci(values):
    """Moyenne et demi-largeur de l'intervalle de confiance à 95 % (loi de Student)."""
    values = np.asarray(values, dtype=float)
    if len(values) < 2:
        return values.mean(), float("nan")
    return values.mean(), t95(len(values) - 1) * values.std(ddof=1) / np.sqrt(len(values))


def total_stats(rewards):
    """Récompense totale moyenne et demi-largeur de son intervalle de confiance à 95 %."""
    return mean_ci(rewards.sum(axis=1, dtype=np.int64))
```

L'intervalle de confiance utilise le quantile de Student (`t95`, 2,26 pour 10 relances, 1,96 pour 1000) plutôt que 1,96 partout, qui serait trop optimiste avec peu de relances.

Test retenu : on calcule deux fois la courbe moyenne avec **deux séries de relances indépendantes**. Si le nombre de relances suffit, les deux courbes se superposent.

Relances	Écart RMS entre les deux courbes	Récompense totale moyenne (IC 95 %)
1	1,120	−870
10	0,365	−865,0 ± 91,4
100	0,120	−834,4 ± 22,5
1000	0,033	−829,5 ± 7,1



L'écart est divisé par environ 3,2 à chaque fois que le nombre de relances est multiplié par 10 : le bruit décroît en 1/√K. **Nous retenons 1000 relances** pour les parties de 1000 étapes : les deux courbes sont alors confondues à 0,03 près, et la récompense totale est connue à ±7 points (±0,007 par étape). Pour les parties de 10 000 étapes, nous utilisons 500 relances afin de limiter le temps de calcul ; nous n'y avons pas refait le test des deux séries, mais l'intervalle de confiance de la récompense totale y est de ±0,003 par étape. Une relance coûte environ 6 µs par étape ; les relances tournent en parallèle sur tous les cœurs.

Question 3.12 - Comparaison de γ = 0 ; 0,1 ; 0,5 ; 0,9 et 1

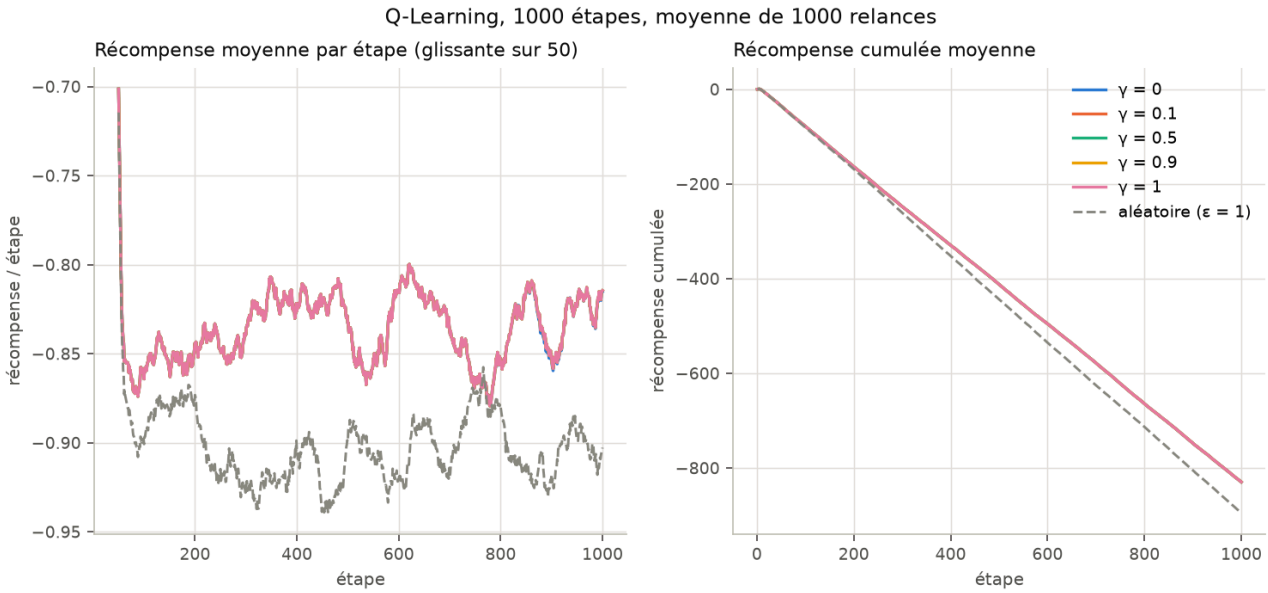
Travail collectif

```python
def compare_gammas(pool, n_steps, n_runs, window, name, title):
    results = {gamma: run_many(pool, gamma, n_steps, n_runs) for gamma in GAMMAS}
    baseline = run_many(pool, 0.5, n_steps, n_runs, eps=1.0)       # joueur aléatoire
    for gamma, rewards in results.items():
        mean_total, ci = total_stats(rewards)
        same = identical_runs(rewards, results[0.5])
        ...   # tableau et graphique


def identical_runs(rewards, reference):
    """Nombre de parties strictement identiques (même graine) à celles de `reference`."""
    return int(np.all(rewards == reference, axis=1).sum())
```

`py ex3_qlearning.py q12` (1000 étapes, 1000 relances, mêmes graines pour chaque γ) :

γ	Récompense totale moyenne (IC 95 %)	Parties identiques à celles de γ = 0,5
0	−829,6 ± 7,1	999 / 1000
0,1	−829,5 ± 7,1	1000 / 1000
0,5	−829,5 ± 7,1	1000 / 1000
0,9	−829,5 ± 7,1	1000 / 1000
1	−829,5 ± 7,1	1000 / 1000
aléatoire (ε = 1)	−894,9 ± 7,9	-



Il n'y a pas de meilleure valeur sur 1000 étapes. Les quatre valeurs γ > 0 produisent exactement les mêmes 1000 parties (les courbes sont superposées), et γ = 0 n'en change qu'une. En revanche, l'IA fait mieux qu'un joueur aléatoire, d'environ 65 points, quelle que soit la valeur de γ.

Pourquoi γ n'a-t-il presque aucun effet ? Une décision ne dépend que de l'**ordre** des valeurs Q(s, a) dans l'état courant, et cet ordre ne dépend presque jamais de γ ici :

- **Chaque paire n'est presque jamais revue.** L'état contient la position du fruit, qui change à chaque fruit mangé. Sur une partie (graine 0), 926 paires sont mises à jour en 1000 étapes, dont seulement 7,4 % plus d'une fois, et aucune plus de 3 fois. À 10 000 étapes, ce taux n'est encore que de 10,7 %.
- **γ est multiplié par une valeur nulle.** Avec Q initialisé à 0, $\max_a Q(s', a)$ vaut presque toujours 0 : les actions de s′ n'ont jamais été essayées, ou n'ont rien rapporté, et une seule action à 0 suffit, puisque les valeurs négatives ne dépassent pas 0. Mesuré sur la même partie : $\max_a Q(s', a) \neq 0$ dans 0,00 % des mises à jour sur 1000 étapes, 0,10 % sur 10 000 et 1,5 % sur 100 000. La cible vaut alors r quel que soit γ. Pour la première mise à jour d'une paire, cas de la grande majorité des paires, Q(s, a) vaut α·r : −5 après un bord, +5 après un fruit, 0 sinon (ou si les deux arrivent au même pas).
- **Le +10 ne remonte pas.** Après un fruit mangé, l'état suivant contient le nouveau fruit, donc des valeurs encore nulles. Les états qui menaient à l'ancien fruit ne sont revus que si un fruit réapparaît sur la même case.

Ces mesures sont faites par `_visit_stats` (`resultats/ex3_visites.csv`) :

```
def _visit_stats(n_steps, gamma=0.5, seed=0):
    """Paires mises à jour, et part des mises à jour où max_a Q(s', a) ≠ 0 (seul cas où γ
compte)."""
    ...
    for _ in range(n_steps):
        action = player.get_action()
        value = game.move(action)
        next_state = game.save_state()
        if max(player._value(next_state, a) for a in actions(next_state)) != 0:
            gamma_matters += 1
        player.reward(action, value)
```

Sur 1000 étapes, l'agent apprend donc seulement à ne pas refaire, dans le même état, un coup qui lui a coûté un bord. C'est ce qui le place au-dessus du joueur aléatoire.

Question 3.13 - Recherche de la meilleure valeur de γ

Travail collectif

```
SWEEP = [round(0.05 * i, 2) for i in range(21)]   # 0, 0.05, ..., 1


def sweep(pool, n_steps, n_runs, gammas=SWEEP):
    """Balaye gamma. Comme toutes les valeurs partagent les mêmes graines, chaque valeur est
    comparée à γ = 0.5 partie par partie (écart apparié), ce qui retire le bruit commun."""
    reference = run_many(pool, 0.5, n_steps, n_runs)
    rows, means = [], {}
    for gamma in gammas:
        rewards = reference if gamma == 0.5 else run_many(pool, gamma, n_steps, n_runs)
        mean_total, ci = total_stats(rewards)
        diff, ci_diff = paired_difference(rewards, reference)
        means[gamma] = mean_total
        rows.append([gamma, n_steps, n_runs, round(float(mean_total), 1), round(float(ci), 1),
                     identical_runs(rewards, reference), round(float(diff), 2),
                     round(float(ci_diff), 2), verdict(diff, ci_diff)])
    best_mean = max(means.values())
    best = [gamma for gamma, mean in means.items() if mean == best_mean]
    ...   # affichage des résultats
    return rows, best

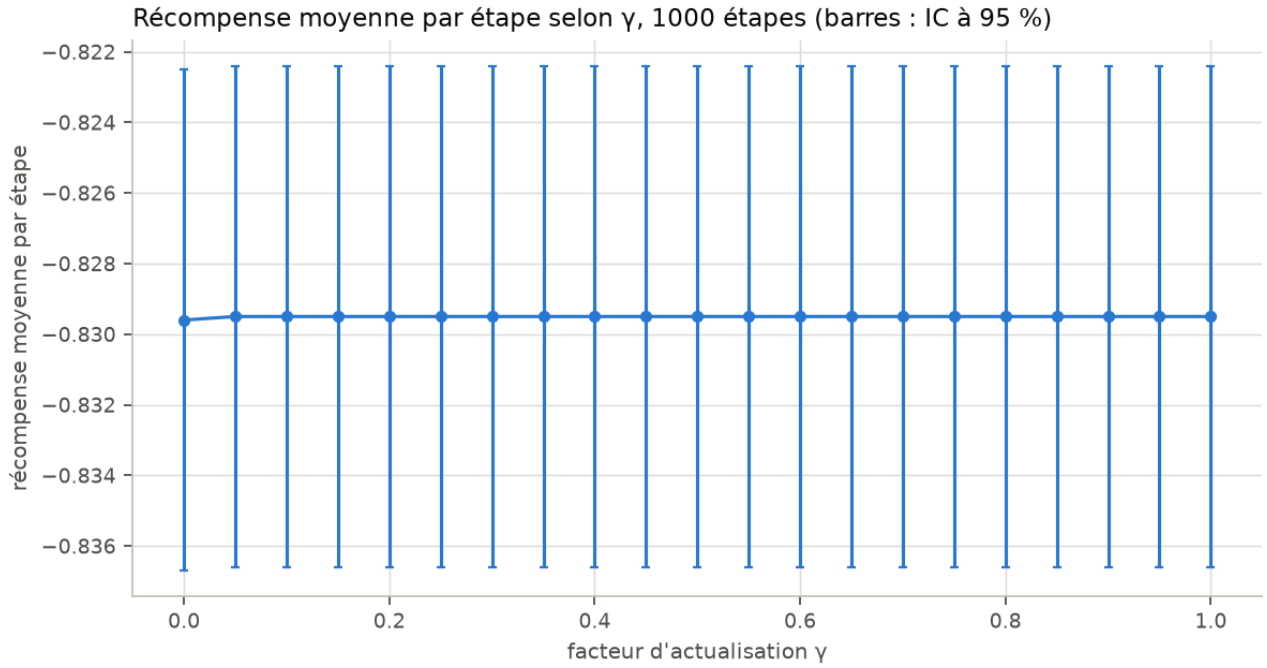

def paired_difference(rewards, reference):
    """Écart moyen de récompense totale avec `reference`, partie par partie (mêmes graines)."""
    return mean_ci(rewards.sum(axis=1, dtype=np.int64) - reference.sum(axis=1, dtype=np.int64))


def verdict(diff, ci):
    """Un écart est significatif si son intervalle de confiance à 95 % ne contient pas 0."""
    if diff == 0:
        return "aucun écart"
    if not np.isfinite(ci):
        return "indéterminé"
    return "significatif" if abs(diff) > ci else "non significatif"
```

`py ex3_qlearning.py q13` balaie γ de 0 à 1 par pas de 0,05, avec 1000 relances de 1000 étapes (`resultats/ex3_q13_recherche.csv`). La meilleure valeur est choisie sur les moyennes non arrondies,

et chaque γ est comparé à γ = 0,5 **partie par partie** : les mêmes graines sont utilisées pour tous les γ, ce qui retire le bruit commun.

γ	Récompense totale moyenne (IC 95 %)	Parties identiques à γ = 0,5	Écart apparié avec γ = 0,5
0	−829,6 ± 7,1	999 / 1000	−0,13 ± 0,26
0,05 à 1 (20 valeurs)	−829,5 ± 7,1	1000 / 1000	0 (parties identiques)



Toutes les valeurs γ ∈]0, 1] sont ex aequo : elles jouent exactement les mêmes parties. Même l'écart apparié avec γ = 0, plus précis que la comparaison des moyennes, n'est pas significatif (−0,13 ± 0,26 : l'intervalle contient 0). Sur 1000 étapes, aucune valeur de γ n'est meilleure qu'une autre : l'agent n'a pas eu le temps de revoir assez d'états pour que γ intervienne.

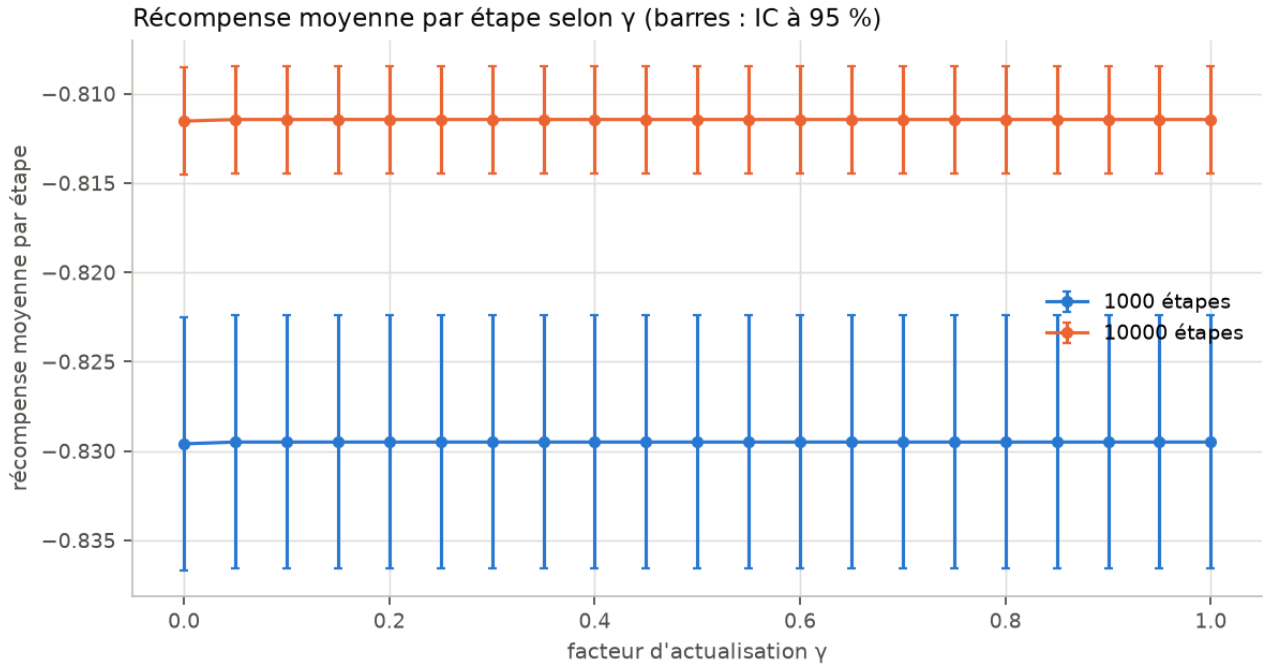
Question 3.14 - Sur 10 000 étapes

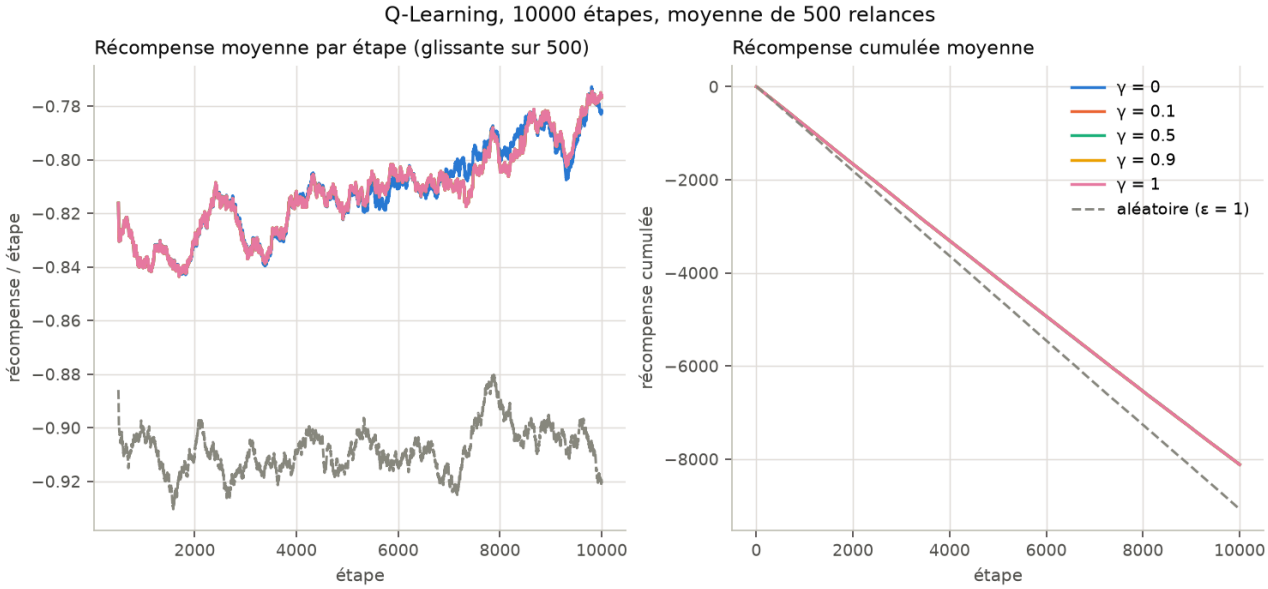
Travail collectif

```
def q14(pool, rows_1000=None):
    rows, best = sweep(pool, 10_000, N_RUNS_LONG)        # 500 relances de 10 000 étapes
    plot_sweep([("1000 étapes", rows_1000), ("10000 étapes", rows)], ...)
    compare_gammas(pool, 10_000, N_RUNS_LONG, 500, "ex3_q14_gammas_10000.png", ...)
```

`py ex3_qlearning.py q14` :

γ	Récompense totale moyenne sur 10 000 étapes (IC 95 %)	Parties identiques à γ = 0,5	Écart apparié avec γ = 0,5
0	−8115,3 ± 29,9	379 / 500	−0,92 ± 12,40
0,05 à 1 (20 valeurs)	−8114,4 ± 30,0	500 / 500	0 (parties identiques)
aléatoire (ε = 1)	−9074,0 ± 39,5	-	-





La meilleure valeur n'a pas changé : toutes les valeurs γ > 0 restent ex aequo et produisent les mêmes parties. γ = 0 se sépare un peu plus (121 parties sur 500 diffèrent), mais l'écart apparié (−0,92 ± 12,40 sur 10 000 étapes) n'est toujours pas significatif. L'apprentissage devient en revanche visible : la récompense par étape passe d'environ −0,83 à −0,78, alors que le joueur aléatoire reste vers −0,91.

Pour aller plus loin - entraînements de 1 000 000 d'étapes

Travail collectif

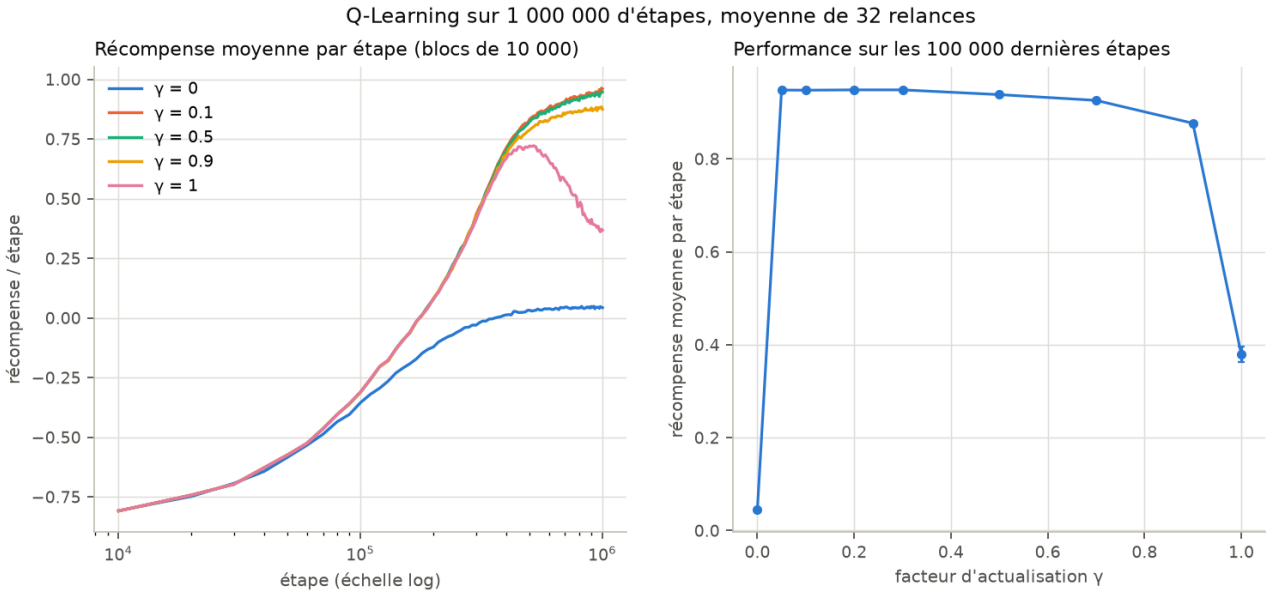
Pour savoir quand γ commence à compter, nous avons prolongé l'entraînement à un million d'étapes (32 relances par valeur de γ, `py ex3_qlearning.py long`).

```
LONG_STEPS = 1_000_000
LONG_GAMMAS = [0, 0.05, 0.1, 0.2, 0.3, 0.5, 0.7, 0.9, 1]


def long_horizon(pool):
    for gamma in LONG_GAMMAS:
        tasks = [(gamma, LONG_STEPS, seed, LONG_BLOCK) for seed in range(LONG_RUNS)]
        blocks = np.array(list(pool.map(_run_blocks, tasks)))   # (relances, blocs)
        ...
        mean_last, ci = mean_ci(blocks[:, -10:].mean(axis=1))      # 100 000 dernières étapes
        mean_total, ci_total = mean_ci(blocks.mean(axis=1))
        ...
    max_q = list(pool.map(_max_q, (0.5, 0.9, 1)))                 # croissance de |Q|
    ...   # tableau et graphique


def _max_q(gamma, seed=0):
    """max |Q| au fil d'une même partie (graine 0), à chaque point de MAX_Q_CHECKPOINTS."""
    game = ShortSnake(SIZE, seed=seed)
    player = GreedyPlayer(game, EPS, alpha=ALPHA, gamma=gamma, seed=1_000_000 + seed)
    done, values = 0, []
    for checkpoint in MAX_Q_CHECKPOINTS:
        play(player, game, checkpoint - done)
        done = checkpoint
        values.append(round(max(abs(v) for v in player.action_values.values()), 2))
    return [gamma, *values]
```

γ	Récompense / étape sur 10^6 étapes	Sur les 100 000 dernières étapes
0	−0,061	0,044 ± 0,002
0,05	0,559	**0,948 ± 0,004**
0,1	0,558	**0,948 ± 0,003**
0,2	0,558	**0,948 ± 0,004**
0,3	0,557	**0,948 ± 0,003**
0,5	0,552	0,938 ± 0,003
0,7	0,545	0,926 ± 0,004
0,9	0,524	0,877 ± 0,003
1	0,354	0,379 ± 0,016



Sur un entraînement long, γ devient décisif :

- **γ = 0** plafonne à 0,04 par étape : l'agent ne voit que la récompense immédiate. Il évite les bords et mange le fruit quand il est juste devant lui, mais ne va pas le chercher.
- **γ ∈ [0,05 ; 0,3]** donne la meilleure performance : un gain net de 0,95 point par étape (fruits mangés moins bords franchis). Un petit γ suffit pour que les cases proches du fruit valent plus que les autres, d'autant plus que le fruit est proche ($10 \cdot \gamma^k$). Au-delà du fruit, l'avenir est aléatoire (nouveau fruit) : le compter fortement ajoute surtout du bruit aux estimations.
- **γ = 1** monte jusqu'à 0,72 puis redescend à 0,38. Sans actualisation, manger le fruit dans 3 coups ou dans 10 coups rapporte autant : rien ne pousse l'agent à se dépêcher. La somme des récompenses n'est pas bornée non plus dans une tâche continue : le cours impose γ < 1 pour qu'elle converge. Les valeurs Q le montrent (`_max_q`, `resultats/ex3_max_q.csv`, une partie de graine 0) :

γ	max |Q| à 10^4 étapes	10^5	$3 \cdot 10^5$	10^6	Borne 10 / (1 − γ)
0,5	7,5	11,2	12,8	13,4	20
0,9	7,5	12,7	16,7	24,7	100
1	7,5	13,4	19,9	31,5	aucune

Pour γ < 1, |Q| ne peut pas dépasser 10 / (1 − γ). Avec γ = 0,5, il plafonne déjà à 13,4. Avec γ = 1, rien ne le limite et il continue de croître. Nous avons mesuré deux faits : |Q| n'est pas borné, et la performance baisse après un pic à 0,72. Le lien entre les deux reste une hypothèse que nous n'avons pas vérifiée : sans actualisation, une valeur additionne toutes les récompenses futures et reflète surtout l'historique des mises à jour, plus que la distance au fruit.

La réponse aux questions 12 à 14 dépend donc de la durée d'entraînement : γ n'a pas d'effet significatif sur 1000 et 10 000 étapes, et un petit γ (0,05 à 0,3) est le meilleur une fois que l'agent a assez joué pour revoir les mêmes états.